Lab09

```
import pandas as pd
import numpy as np
from plotnine import *
from plotnine.data import diamonds

df_diamonds = diamonds.copy()
df_diamonds.head()
```

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43
1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

1.Importe o conjunto de dados diamonds, cujo arquivo está disponível no website da disciplina.

```
import pandas as pd
import numpy as np
from plotnine import *
from plotnine.data import diamonds

df_diamonds = diamonds.copy()

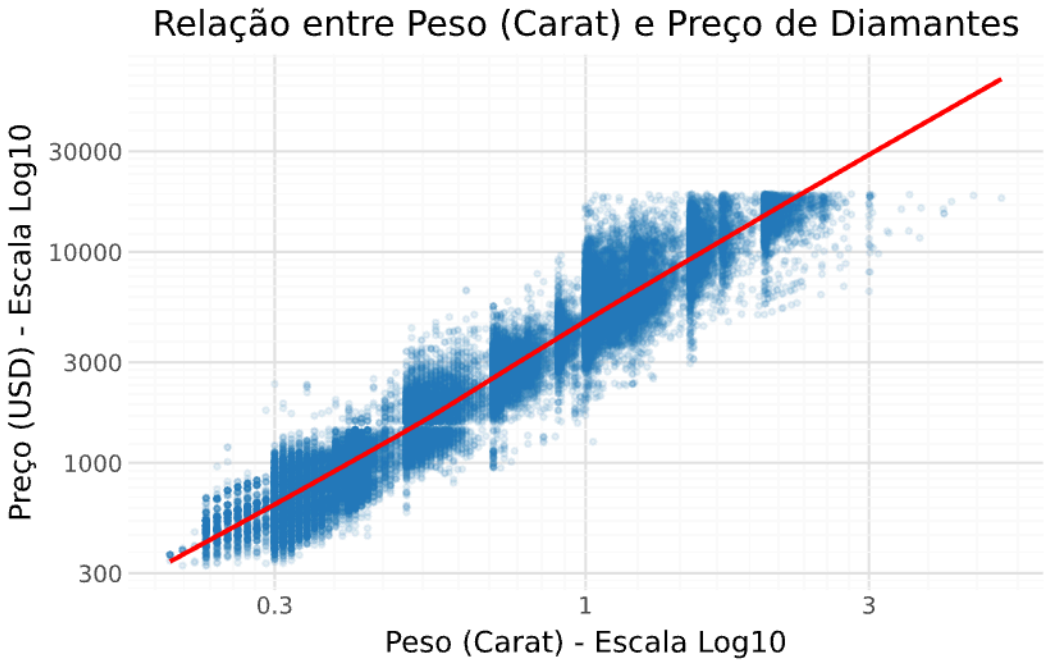
print(df_diamonds.head())
```

```
   carat      cut color clarity  depth  table  price     x     y     z
0   0.23    Ideal     E     SI2   61.5   55.0    326  3.95  3.98  2.43
```

```
1    0.21  Premium     E     SI1   59.8   61.0    326  3.89  3.84  2.31
2    0.23     Good     E     VS1   56.9   65.0    327  4.05  4.07  2.31
3    0.29  Premium     I     VS2   62.4   58.0    334  4.20  4.23  2.63
4    0.31     Good     J     SI2   63.3   58.0    335  4.34  4.35  2.75
```

2.Crie uma visualização de dados que descreva a associação existente entre as variáveis peso (carat) e preço (price). Que ações você tomou para garantir que você produziu um gráfico de boa qualidade? Escreva um parágrafo comunicando os seus achados.

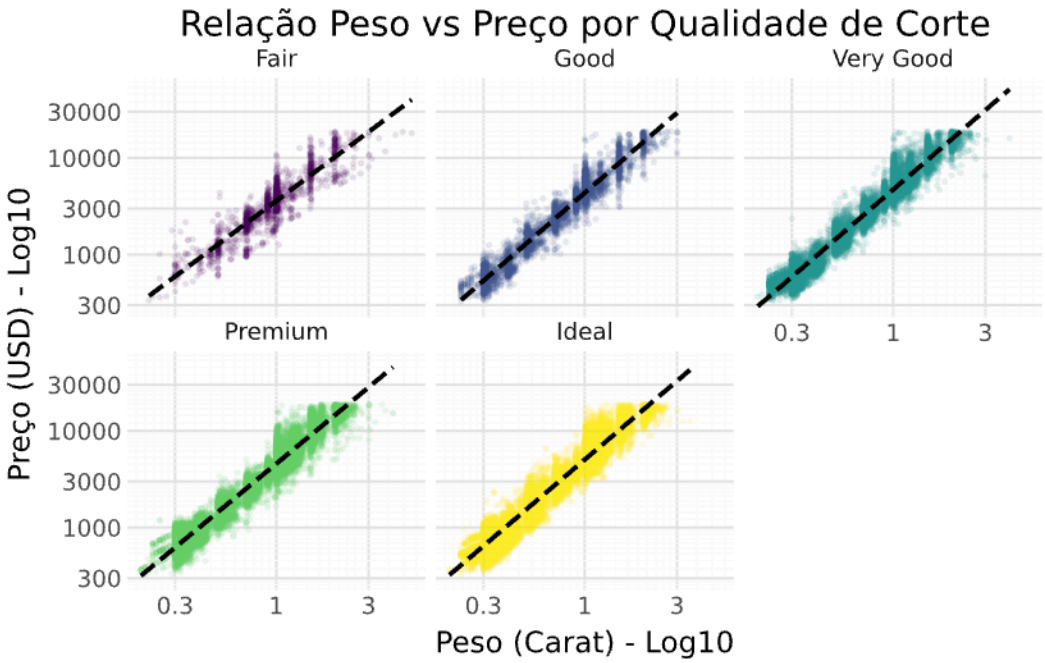
```
(
    ggplot(df_diamonds, aes(x='carat', y='price'))
    + geom_point(alpha=0.1, size=0.8, color='#1f77b4')
    + geom_smooth(method='lowess', color='red', se=False)
    + scale_x_log10()
    + scale_y_log10()
    + labs(
        title="Relação entre Peso (Carat) e Preço de Diamantes",
        x="Peso (Carat) - Escala Log10",
        y="Preço (USD) - Escala Log10"
    )
    + theme_minimal()
)
```



R: Para garantir um gráfico de boa qualidade e sem poluição visual (overplotting), apliquei transparência (alpha=0.1) e redução no tamanho dos pontos (size=0.8), além de utilizar escala logarítmica (log10) nos eixos X e Y para ajustar a assimetria dos dados e adicionei uma curva de tendência LOWESS para destacar o padrão geral. Podemos concluir que existe uma forte relação positiva e exponencial entre peso (carat) e preço (price), indicando que o valor do diamante cresce em ritmo muito superior ao aumento de sua massa. Além disso, observam-se concentrações verticais de pontos em números redondos de quilates (ex: 0.5, 0.7, 1.0, 1.5 e 2.0), demonstrando que o mercado de lapidação precifica com saltos de valor ao atingir marcas inteiras ou fracionárias marcantes.

3.A relação identificada na questão anterior é a mesma relação presente nos diferentes cortes de diamantes? Crie uma visualização que demonstre seus achados eficientemente. Descreva sua conclusão em um parágrafo

```
(
    ggplot(df_diamonds, aes(x='carat', y='price', color='cut'))
    + geom_point(alpha=0.08, size=0.5)
    + geom_smooth(method='lm', color='black', linetype='dashed', se=False)
    + scale_x_log10()
    + scale_y_log10()
    + facet_wrap('~cut', ncol=3)
    + labs(
        title="Relação Peso vs Preço por Qualidade de Corte",
        x="Peso (Carat) - Log10",
        y="Preço (USD) - Log10"
    )
    + theme_minimal()
    + theme(legend_position='none')
)
```



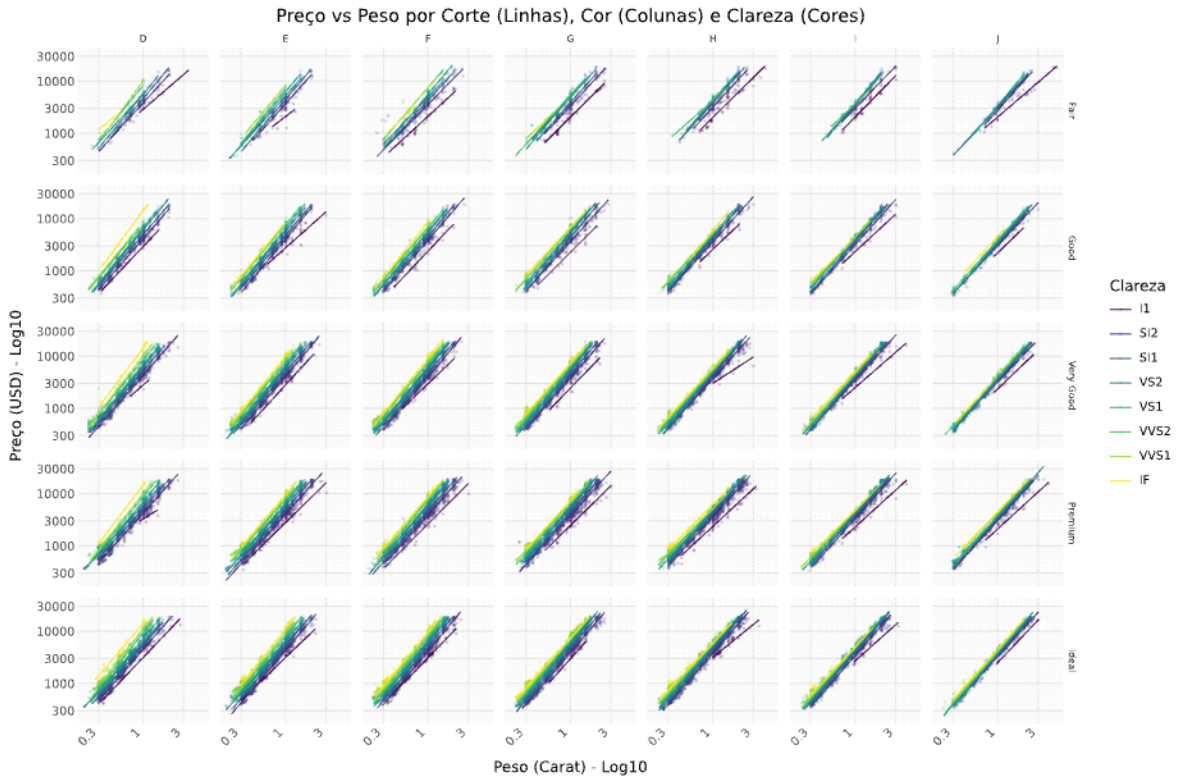
R: Sim, a relação positiva e exponencial entre peso e preço é a mesma em todos os cortes. Em todas as categorias, a inclinação das retas é praticamente idêntica, confirmando que o peso dita a alta do valor em qualquer grupo. A única diferença é o patamar: para o mesmo peso, cortes superiores (Ideal e Premium) custam ligeiramente mais do que o corte Fair.

4.Crie uma visualização que mostre a relação entre preço e peso do diamante, considerando as diferentes combinações de qualidade de corte, cor e clareza do diamante. Quais foram as dificuldades encontradas? A relação entre preço e peso é a mesma para diferentes configurações de diamantes?

```
(
    ggplot(df_diamonds, aes(x='carat', y='price', color='clarity'))
    + geom_point(alpha=0.15, size=0.4)
    + geom_smooth(method='lm', se=False, size=0.5)
    + scale_x_log10()
    + scale_y_log10()
    + facet_grid('cut ~ color')
    + labs(
        title="Preço vs Peso por Corte (Linhas), Cor (Colunas) e Clareza (Cores)",
        x="Peso (Carat) - Log10",
        y="Preço (USD) - Log10",
        color="Clareza"
    )
    + theme_minimal()
```

```
    + theme(
        figure_size=(12, 8),
        strip_text=element_text(size=7),
        axis_text_x=element_text(rotation=45, hjust=1)
    )
)
```

```
C:\Users\Usuario\AppData\Local\R\cache\R\reticulate\uv\cache\archive-v0\1mQN8iL23wnrcZty\Lib
C:\Users\Usuario\AppData\Local\R\cache\R\reticulate\uv\cache\archive-v0\1mQN8iL23wnrcZty\Lib
C:\Users\Usuario\AppData\Local\R\cache\R\reticulate\uv\cache\archive-v0\1mQN8iL23wnrcZty\Lib
C:\Users\Usuario\AppData\Local\R\cache\R\reticulate\uv\cache\archive-v0\1mQN8iL23wnrcZty\Lib
C:\Users\Usuario\AppData\Local\R\cache\R\reticulate\uv\cache\archive-v0\1mQN8iL23wnrcZty\Lib
```



R: O principal desafio foi a alta poluição visual ao combinar 5 variáveis (280 subgrupos), resolvida dividindo o gráfico em uma matriz de subpainéis (facet_grid('cut ~ color')) e usando cores para a clareza.

Conclusão: Sim, a tendência positiva entre peso e preço se mantém em todas as configurações. No entanto, o nível de preço muda bastante: combinações nobres (Cor D, Clareza IF) formam

retas muito mais elevadas que as inferiores (Cor J, Clareza I1), mostrando que cor e clareza multiplicam o valor base do quilate.